

An Explainable AI-Based Intrusion Detection System for DNS Over HTTPS (DoH) Attacks

Tahmina Zebin, Shahadate Rezvy e Yuan Luo | IEEE Transactions on Information Forensics and Security, 2022

Daniel Nascimento Lucas Alves Maria Carolina Millena Neves

O desafio: Criptografia esconde ameaças

DNS-over-HTTPS (DoH)

Criptografa requisições DNS:
protege privacidade, mas
"cega" administradores de rede

Tunneling Malicioso

Malwares exploram essa
cegueira para exfiltração
de dados e comunicação,
mascarada como
navegação comum



Arquitetura: Balanced Stacked RF

Validação Cruzada

Previsão out-of-fold
evita data leakage

Dados separados

Treinados em blocos de dados
distintos

Camada 1

Três Random Forests
paralelas

Meta-classificador

Logistic Regression combina
previsões

Decisão Final

Cada RF: 10 árvores,
profundidade 5



Processo de replicação



Pré-processamento "cirúrgico"

→ **Limpeza**

Remoção de IPs, Portas e Timestamps

→ **Montagem**

União L1 + L2 $\Rightarrow$ 3 classes

→ **Seleção**

29 características comportamentais

→ **Normalização**

Min-Max Scaler [0, 1]



A metodologia na prática: memória e validação

Divisão em blocos

~900k pacotes Non-DoH
divididos em 3 blocos

SMOTE

Oversampling sintético da
classe Benign

(aplicado exclusivamente nos dados de treino)

Rigor do 10-Fold CV

Eliminação total de *data*
leakage entre camadas do stack



Resultados: Reproduzindo o sucesso

Classe	Precisão	Recall	F1-Score
Non-DoH (Navegação Normal)	0.99	0.99	0.99
Malicious-DoH (Ataque)	0.98	0.98	0.98
Benign-DoH (Classe Minoritária)	0.81	0.45	0.58




Explicabilidade (XAI) :

Painel SHAP

Transparência Predidita

Utilizamos o SHAP para mapear as features mais influentes na detecção de ataques.



Novo dataset

e melhorias



Mesma arquitetura, dataset diferente



- **CIRA-CIC-DoHBrw-2020-and-DoH-Tunnel-Traffic-HKD**
Dataset original (CIRA-CIC-DoHBrw-2020) + novas instâncias geradas por ferramentas de tunneling diferentes
- **Layer 1 + Layer 2 (45 : 1 : 18)**
NonDoH, BenignDoH, MaliciousDoH
- **Layer 1 + Layer 2 + Layer 3 (45 : 8 : 2 : 2 : 2 : 2 : 1 : 1)**
NonDoH, BenignDoH, dns2tcp, iodine, dnscat2, dnstt, tcp_over_dns, tuns



Comparação dos Resultados - Replicando a Arquitetura

	Acurácia	F1	Precisão	Recall
Trabalho Original	0.9998	0.9991	0.9991	0.9992
Novo Dataset	0.99	0.97	0.92	0.94

Feature Importances



Nossa Proposta

- **Buscar classificar as ferramentas de tunneling propriamente ditas**
Em vez de trabalharmos com 3 classes, trabalhamos com 8
- **Utilizamos o Layer 1 + Layer 2 + Layer 3**
NonDoH, BenignDoH, dns2tcp, iodine, dnscat2, dnstt, tcp_over_dns, tuns
- **Novo Particionamento**
Para equilibrar as proporções entre as novas classes (45 : 8 : 2 : 2 : 2 : 2 : 1 : 1), dividimos a classe majoritária (DoH) em 5 partições em vez de 3 antes de aplicar o SMOTE.



Proporção das classes

- **Metodologia abordada**




Seguindo a metodologia proposta no projeto, é fundamental manter o desbalanceamento até o treino para em seguida aplicarmos o SMOTE

Label	
NonDoH	889809
dns2tcp	167287
iodine	46524
dnstt	46080
dnscat2	35742
tcp-over-dns	30040
tuns	29040
Benign	19746

Label	
NonDoH	800828
MaliciousDoH_dns2tcp	150558
MaliciousDoH_iodine	41872
MaliciousDoH_dnstt	41472
MaliciousDoH_dnscat2	32168
MaliciousDoH_tcp_over_dns	27036
MaliciousDoH_tuns	26136
BenignDoH	17771



Proporção das classes



Mesmo passo a passo do original

- **SMOTE: dns2tcp**

É a segunda classe majoritária.

- **Regressão Logística**


Mesmo meta-modelo utilizado originalmente.

- **Novo Particionamento**

Cada partição possui a proporção 9:8:2:2:2:2:1:1. Após a aplicação do SMOTE considerando a segunda classe majoritária, a proporção final para cada partição dos RF fica 1:1:1:1:1:1:1:1.



Resultados Random Forest




Resultados com todas as features:

	precision	recall	f1-score	support
0	0.99	0.98	0.98	2971
1	0.98	0.99	0.98	3000
2	1.00	1.00	1.00	2614
accuracy			0.99	8585
macro avg	0.99	0.99	0.99	8585
weighted avg	0.99	0.99	0.99	8585



Resultados



	precision	recall	f1-score	support
BenignDoH	0.84	0.92	0.87	1975
MaliciousDoH_dns2tcp	1.00	0.98	0.99	16729
MaliciousDoH_dnscat2	0.87	0.93	0.90	3574
MaliciousDoH_dnstt	1.00	1.00	1.00	4608
MaliciousDoH_iodine	0.92	0.94	0.93	4652
MaliciousDoH_tcp_over_dns	1.00	1.00	1.00	3004
MaliciousDoH_tuns	1.00	1.00	1.00	2904
NonDoH	1.00	1.00	1.00	88981
accuracy			0.99	126427
macro avg	0.95	0.97	0.96	126427
weighted avg	0.99	0.99	0.99	126427



Muito
obrigado!

